

Поповкин Артемий Андреевич
Б9122-02.03.01 СЦТ

Постановка задачи

Требуется для модели **Лотки-Вольтерры** определить численность популяции в будущем на основе начальной численности жертв и хищников, темпов роста обеих популяций и коэффициентов, отражающих взаимодействия между ними.

Описание модели

Описание

Модель Лотки-Вольтерры описывает динамику взаимодействия двух биологических видов с отношениями "Хищник-Жертва" или "Паразит-Хозяин".

Обозначения

- t — время (размерность: годы)

Входные данные

- H_0 — начальная численность популяции хищников (размерность: тысячи)
- P_0 — начальная численность популяции жертв (размерность: тысячи)

Фазовые переменные

- $H(t)$ — численность популяции хищников в момент времени t .
- $P(t)$ — численность популяции жертв в момент времени t .

Параметры

- α — коэффициент рождаемости жертв.
- β — коэффициент убийства жертв хищниками.
- γ — коэффициент смертности хищников.
- δ — коэффициент рождаемости хищников.

Уравнение

$$\begin{cases} \dot{P} = (\alpha - \beta H)P \\ \dot{H} = (-\gamma + \delta P)H \end{cases}$$

Решением уравнения будет называть функцию, удовлетворяющую следующей задаче Коши:

$$\begin{cases} \dot{P} = (\alpha - \beta H)P \\ \dot{H} = (-\gamma + \delta P)H \\ P(0) = P_0 \quad H(0) = H_0 \end{cases}$$

Аналитическое исследование системы

Условие устойчивости

Для начала найдём равновесия модели:

$$\begin{cases} (\alpha - \beta H)P = 0 \\ (-\gamma + \delta P)H = 0 \end{cases}$$

Решив систему, получаем следующие два равновесия:

Тривиальное

$$P_t = H_t = 0$$

Нетривиальное

$$\begin{cases} \alpha - \beta H = 0 \\ -\gamma + \delta P = 0 \end{cases} \implies \begin{cases} H_{nt} = \frac{\alpha}{\beta} \\ P_{nt} = \frac{\gamma}{\delta} \end{cases}$$

Теперь исследуем полученные равновесные точки на устойчивость.

Для этого найдём собственные значения матрицы Якоби системы в данных точках.

$$J - \lambda E = \begin{pmatrix} \alpha - \beta H - \lambda & -\beta P \\ \delta H & -\gamma + \delta P - \lambda \end{pmatrix}$$

Тривиальное равновесие

$$\det(J - \lambda E) \Big|_{P=P_t, H=H_t} = -(\alpha - \lambda)(\gamma + \lambda) = 0 \implies \begin{cases} \lambda_1 = \alpha \\ \lambda_2 = -\gamma \end{cases}$$

Так как $\text{Im } \lambda_{1,2} = 0$, $\text{Re } \lambda_1 > 0$, $\text{Im } \lambda_2 < 0$, можем заключить, что тривиальное равновесие неустойчиво и является седловой точкой.

Нетривиальное равновесие


$$\det(J - \lambda E) \Big|_{x=x_{nt}, y=y_{nt}} = \lambda^2 + \alpha\gamma = 0 \implies \lambda_{1,2} = \pm \sqrt{\alpha\gamma} i$$

Исходя из того, что $\text{Re } \lambda_{1,2} = 0$, $\text{Im } \lambda_1 > 0$, $\text{Im } \lambda_2 < 0$, получаем, что нетривиальное равновесие является центром (устойчиво).

Численные эксперименты

Был выбран временной диапазон с 1900 по 1920 гг.

Популяция зайцев и рысей указана в тысячах.





Основные расчёты


Для численного решения задачи Коши, описывающей нашу модель, был выбран метод семейства Кунге-Кутты 4 порядка, в силу его достаточной точности и простоты реализации.

Для подбора параметров использовался нелинейный метод наименьших квадратов, предоставляемый пакетом `scipy` языка программирования Python.

В итоге были получены оптимальные параметры и численно найдены решения системы ДУ. Сравнение модельных и реальных данных представлено на рисунках 1-2.



Используя полученную модель был построен прогноз динамики экосистемы на следующие 10 лет. Результат на 3-м рисунке



Заключение

В результате проведенного исследования была успешно применена модель Лотки-Вольтерры для анализа реальных данных о популяциях рыси и зайца.

Аналитическое исследование системы позволило идентифицировать два состояния равновесия: тривиальное, являющееся неустойчивым, и нетривиальное, которое представляет собой устойчивый центр.

Это теоретически подтверждает циклический, колебательный характер взаимодействия хищника и жертвы, наблюдаемый в природе.

Практическим итогом работы стала численная реализация модели. С помощью нелинейного метода наименьших квадратов были подобраны оптимальные параметры системы, что позволило добиться качественного соответствия модельных траекторий реальным данным.

Как видно из графиков, модель корректно воспроизводит общий тренд, хотя и не всегда точно совпадает с конкретными точками, что обуславливается простотой предположенной модели.

Таким образом, классическая модель «хищник-жертва» подтвердила свою адекватность для качественного анализа динамики данной экосистемы.

Использованные данные

<https://mc-stan.org/learn-stan/case-studies/lotka-volterra-predator-prey.html#data-lynx-and-hare-pelts-in-canada>

<https://github.com/stan-dev/example-models/blob/master/knitr/lotka-volterra/hudson-bay-lynx-hare.csv>

Листинг кода

```
# Imports
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from scipy.optimize import minimize
from scipy.integrate import solve_ivp

# Funcs
## Math
def objective(
    params: tuple[float, float, float, float], data: tuple[float, float,
float], y0
):
    H_data, L_data, t_data = data
    y_pred = model(params, t_data, y0)
    error_H = np.mean((y_pred[0] - H_data) ** 2)
    error_L = np.mean((y_pred[1] - L_data) ** 2)
    return error_H + error_L

def model(params: tuple[float, float, float, float], t, y0):
    solution = solve_ivp(
        lotka_volterra, [t[0], t[-1]], y0, args=(params), t_eval=t,
method="RK45"
    )
    return solution.y

def lotka_volterra(t, y, alpha, beta, delta, gamma):
    # alpha, beta, delta, gamma = params
    H, L = y
    dHdt = alpha * H - beta * H * L
    dLdt = delta * H * L - gamma * L
    return [dHdt, dLdt]
```

```

def runge_kutta_4th_order(
    f, y0, t_span, n_steps: int, params: tuple[float, float, float, float]
):
    alpha, beta, delta, gamma = params
    t_start, t_end = t_span
    t = np.linspace(t_start, t_end, n_steps)
    h = (t_end - t_start) / (n_steps - 1)
    y = np.zeros((len(y0), n_steps))
    y[:, 0] = y0
    for i in range(n_steps - 1):
        k1 = h * np.array(f(t[i], y[:, i], alpha, beta, delta, gamma))
        k2 = h * np.array(f(t[i] + h / 2, y[:, i] + k1 / 2, alpha, beta,
delta, gamma))
        k3 = h * np.array(f(t[i] + h / 2, y[:, i] + k2 / 2, alpha, beta,
delta, gamma))
        k4 = h * np.array(f(t[i] + h, y[:, i] + k3, alpha, beta, delta,
gamma))
        y[:, i + 1] = y[:, i] + (k1 + 2 * k2 + 2 * k3 + k4) / 6
    return t, y

# Data
df = pd.read_csv("../data/hudson-bay-lynx-hare.csv")
df

P_col_name = "Hare"
H_col_name = "Lynx"
t_col_name = "Year"

t_data = df[t_col_name].values
H_data = df[P_col_name].values
L_data = df[H_col_name].values
data = (H_data, L_data, t_data)

y0 = [H_data[0], L_data[0]]
# Calculation
## Params calculation
initial_guess = [1.0, 0.1, 0.01, 0.375]
bounds = [(0.001, 10), (0.001, 1), (0.001, 1), (0.001, 1)]

result = minimize(objective, initial_guess, args=(data, y0), bounds=bounds,
method="L-BFGS-B")
params = result.x
alpha, beta, delta, gamma = params
alpha, beta, delta, gamma
## Calculation on hystorical data

```

```

H0 = df[P_col_name].iloc[0]
L0 = df[H_col_name].iloc[0]
t_span = (df[t_col_name].iloc[0], df[t_col_name].iloc[-1])
n_steps = 1000
y0 = [H0, L0]
t_rk, y_rk = runge_kutta_4th_order(lotka_volterra, y0, t_span, n_steps,
params)
# Visualisation
# Визуализация результатов
plt.figure(figsize=(15, 10))
plt.plot(
    df[t_col_name],
    df[P_col_name],
    "dodgerblue",
    label="Реальные данные: зайцы",
    zorder=2,
)
plt.plot(
    df[t_col_name], df[H_col_name], "limegreen", label="Реальные данные:
рыси", zorder=2
)
plt.plot(t_rk, y_rk[0], "royalblue", linestyle="--", label="Модель: зайцы",
zorder=1)
plt.plot(t_rk, y_rk[1], "forestgreen", linestyle="--", label="Модель: рыси",
zorder=1)
plt.legend()
plt.xlabel("Год")
plt.ylabel("Численность")
plt.plot()

# Фазовый портрет
plt.figure(figsize=(15, 10))
plt.plot(df[P_col_name], df[H_col_name], "darkred", label="Реальные данные",
zorder=2)
plt.plot(y_rk[0], y_rk[1], "red", linestyle="--", label="Модельные данные",
zorder=1)
plt.legend()
plt.xlabel("Численность зайцев")
plt.ylabel("Численность рысей")
plt.plot()
H0_forecast = y_rk[0][-1]
L0_forecast = y_rk[1][-1]
last_year = df[t_col_name].iloc[-1]
# Период прогноза
forecast_years = 10
t_span_forecast = (last_year, last_year + forecast_years)

```



```

n_steps_forecast = 1000
# Прогноз с использованием последних известных значений
t_forecast, y_forecast = runge_kutta_4th_order(
    lotka_volterra,
    [H0_forecast, L0_forecast],
    t_span_forecast,
    n_steps_forecast,
    params,
)
# Визуализация прогноза
plt.figure(figsize=(15, 10))
# Исторические данные
plt.plot(
    df[t_col_name],
    df[P_col_name],
    "dodgerblue",
    label="Исторические данные: зайцы",
    linewidth=2,
)
plt.plot(
    df[t_col_name],
    df[H_col_name],
    "limegreen",
    label="Исторические данные: рыси",
    linewidth=2,
)
# Модель на историческом периоде
plt.plot(t_rk, y_rk[0], "blue", linestyle="--", label="Модель: зайцы",
alpha=0.7)
plt.plot(t_rk, y_rk[1], "green", linestyle="--", label="Модель: рыси",
alpha=0.7)
# Прогноз
plt.plot(
    t_forecast, y_forecast[0], "red", linestyle="--", label="Прогноз: зайцы",
    linewidth=2
)
plt.plot(
    t_forecast,
    y_forecast[1],
    "orange",
    linestyle="--",
    label="Прогноз: рыси",
    linewidth=2,
)
# Вертикальная линия разделяющая историю и прогноз
plt.axvline(

```

```
        x=last_year, color="black", linestyle=":", alpha=0.7, label="Начало  
прогноза"  
    )  
plt.legend()  
plt.xlabel("Год")  
plt.ylabel("Численность")  
plt.show()
```